

# Унификация токенизации: поиск оптимальной стратегии для моделей временных рядов

Вдонин Алексей Васильевич

БПМИ224

Руководитель: Темирханов Азиз Арсенович, младший научный сотрудник лаборатории LAMBDA.

НИУ ВШЭ · ФКН · 2026

# Контекст и мотивация

Прогнозирование многомерных временных рядов - ключевая задача ML в энергетике, финансах, климате и транспорте. Доминирующая архитектура - **трансформер**, а центральное проектное решение - стратегия токенизации.

## Точечная

Каждый момент времени - отдельный токен

## Патч-ориентированная

Группа соседних точек одного канала

## Поканальная

Вся история отдельной переменной

## Дискретная

Из числовых значений в дискретные символы

Проблема: сравнения проводились при разных архитектурах и бюджетах, из-за чего невозможно изолировать эффект стратегии токенизации

# Обзор литературы: непрерывные стратегии

| Стратегия            | Токен                       | Длина L                                                           | Источник            |
|----------------------|-----------------------------|-------------------------------------------------------------------|---------------------|
| Точечная             | Одно значение в момент t    | $L_{\text{point}} = T$                                            | Ранние трансформеры |
| Патч-ориентированная | Патч из p соседних значений | $L_{\text{patch}} = \left\lfloor \frac{T-p}{s} \right\rfloor + 1$ | PatchTST            |
| Поканальная          | Вся история одного канала   | $L_{\text{variate}} = C$                                          | iTransformer        |

Каждая стратегия задаёт своё индуктивное смещение задолго до слоя внимания

# Обзор литературы: дискретные стратегии

Дискретные стратегии создают мост между числовыми сигналами и словарными моделями, неизбежно теряя часть информации при квантовании.



## Chronos

Прямое квантование;  
масштабирование + квантование в фиксированный словарь  
 $V=4096$ .



## TOTEM

Обучаемая кодовая книга, переиспользуемая кросс-доменно.



## LLMTime

1. Запись чисел в текст
2. Подача в LLM без дообучения.



## BPE для TS

Byte pair encoding: объединение частых последовательностей в составные токены

# Формальная постановка задачи

## Входные данные

$$X \in \mathbb{R}^{C \times T}$$

C - число каналов, T - длина контекста

## Токенизация

$$\tau : \mathbb{R}^{C \times T} \rightarrow Z^L, \quad Z = (z_1, \dots, z_L)$$

## Стоимость внимания

$$\text{Cost}_{\text{attn}}(\tau) = \mathcal{O}(L_\tau^2 \cdot d)$$

## Функционал полезности

$$U(\tau) = w_q \cdot \tilde{Q} - w_t \cdot \tilde{T} - w_m \cdot \tilde{M} + w_s \cdot \tilde{S}$$

$\tilde{Q}$  - качество прогноза (MAE),

$\tilde{T}$  - затраты на обучение,

$\tilde{M}$  - пиковое потребление памяти,

$\tilde{S}$  - устойчивость к случайной инициализации.

# Исследовательские вопросы

1

## RQ1: Сравнение качества

Как пять стратегий токенизации различаются по качеству прогноза в условиях контролируемого эксперимента?

2

## RQ2: Свойства данных

Какие свойства данных (размерность  $C$ , горизонт  $H$ ) ассоциированы с относительным успехом конкретной стратегии?

3

## RQ3: Решающее правило

Можно ли сформулировать правило, recommending стратегию в зависимости от свойств датасета?

# Методология: двухуровневый протокол

## Уровень 1 - Реализация

Общий бэкбон: все 5 стратегий подаются на один и тот же трансформер-энкодер с идентичными гиперпараметрами, оптимизатором и бюджетом обучения.

**Цель:** изолировать эффект самой токенизации

## Уровень 2 - Литературный контекст

Именованные модели: PatchTST, iTransformer, Chronos, TOTEM - каждая со своей архитектурой. Используются для обсуждения, но не воспроизводятся эмпирически.

# Пять сравниваемых стратегий

| # | Стратегия       | Семейство            | Длина L                                             | Формула токена                                                                                         |
|---|-----------------|----------------------|-----------------------------------------------------|--------------------------------------------------------------------------------------------------------|
| 1 | point           | Точечная             | $T = 336$                                           | $z_{c,t} = \varphi(x_{c,t})$                                                                           |
| 2 | patch           | Патч-ориентированная | $\left\lfloor \frac{T-p}{s} \right\rfloor + 1 = 41$ | $z_{c,i} = \varphi(X_{c,t_i:t_i+p-1}),$ $p = 16, s = 8$                                                |
| 3 | variate         | Поканальная          | $C$                                                 | $z_c = \varphi(X_{c,1:T}),$<br>$\varphi$ - двухслойный MLP                                             |
| 4 | discrete_scalar | Дискр. скалярная     | $T = 336$                                           | $\tilde{x}_{c,t} = \frac{x_{c,t}}{ \bar{x}_c },$ $z_{c,t} = Q(\tilde{x}_{c,t}) \in \{1, \dots, 4096\}$ |
| 5 | discrete_bpe    | Дискр. + BPE         | переменная                                          | BPE поверх скалярного                                                                                  |

Все токенизаторы применяются поканально и выдают токены согласованного формата для единого бэкбона



# Экспериментальная матрица: 90 запусков

| Параметр      | Значения                                   |
|---------------|--------------------------------------------|
| Токенизатор   | 5 стратегий                                |
| Датасет (C)   | ETTh1 (7), Weather (21), Electricity (321) |
| Контекст T    | 336                                        |
| Горизонт H    | 96, 336                                    |
| Инициализации | 2021, 2022, 2023                           |

$5 \times 3 \times 2 \times 3 = 90$  запусков, все завершены успешно

## Аппаратура и бэкбон

**Бэкбон: энкодер-only трансформер**

d=128, h=16, L=3 слоя,  
AdamW, bf16-mixed

**Аппаратура: RTX 5090**

Все эксперименты  
проведены на 1x NVIDIA  
RTX 5090 (32 ГБ), ~230  
GPU-часов (9.5 суток)

# RQ1: Сводные метрики качества (MAE)

| Dataset / H       | point        | patch        | variate | disc_scalar | disc_bpe |
|-------------------|--------------|--------------|---------|-------------|----------|
| ETTh1 / 96        | 0.484        | <b>0.427</b> | 0.447   | 0.548       | 0.668    |
| ETTh1 / 336       | 0.539        | <b>0.523</b> | 0.535   | 0.619       | 0.789    |
| Weather / 96      | 0.226        | <b>0.224</b> | 0.237   | 0.259       | 0.310    |
| Weather / 336     | <b>0.312</b> | 0.339        | 0.388   | 0.343       | 0.518    |
| Electricity / 96  | 0.276        | <b>0.227</b> | 0.247   | 0.294       | 0.761    |
| Electricity / 336 | 0.285        | <b>0.263</b> | 0.282   | 0.295       | 0.802    |

patch - лучший в 5 из 6 ячеек. Исключение: Weather/H=336 (point).


Дискретные стратегии уступают непрерывным во всех ячейках.

# Вычислительные затраты: расхождение до 186×

| Токенизатор     | Итого (18 запусков) |
|-----------------|---------------------|
| variate         | 1.3 ч               |
| patch           | 4.5 ч               |
| discrete_bpe    | 25.5 ч              |
| point           | 65.5 ч              |
| discrete_scalar | 133.4 ч             |

$$\text{Cost}_{\text{attn}}(\tau) = O(L_{\tau}^2 \cdot d)$$

Следовательно длина последовательности  $L$  доминирует над всеми прочими факторами



# Ранжирование по функционалу полезности

| Токенизатор         | U<br>(равная) | U<br>(качество) | U<br>(деплой) |
|---------------------|---------------|-----------------|---------------|
| patch               | 0.426         | 0.757           | 0.313         |
| variate             | 0.269         | 0.636           | 0.206         |
| point               | 0.158         | 0.618           | 0.051         |
| discrete_scala<br>r | -0.037        | 0.425           | -0.253        |
| discrete_bpe        | -0.162        | -0.065          | -0.377        |

## Три конфигурации весов

- 1

Равная

$w = (0.25, 0.25, 0.25, 0.25)$
- 2

На качество

$w = (0.70, 0.10, 0.10, 0.10)$
- 3

На деплой

$w = (0.25, 0.40, 0.25, 0.10)$

patch доминирует при всех трёх конфигурациях - без компромисса между качеством и стоимостью

# Парето-анализ: качество vs. затраты

→ **patch и variate**

patch - на парето-границе по обеим осям, variate - по оси времени обучения













→ **point и discrete\_scalar**

Доминируются - не дают выигрыша по качеству, но требуют кратно больших вычислений

→ **Electricity / discrete\_scalar**

Худший компромисс качество/стоимость: до ~24 ч обучения на одну инициализацию - наглядный антипример

Парето-анализ подтверждает: patch - доминирующая стратегия



# RQ2 & RQ3: Зависимость от размерности и решающее правило


Решающее правило с единственным исключением:

$\tau^* = \text{patch}$  (в 5 из 6 ячеек)

Исключение: Weather,  $H = 336 \Rightarrow \tau^* = \text{point}$

## RQ2: Зависимость ранга от размерности C

- patch удерживает ранг 1 на всём диапазоне C при  $H = 96$
- patch - ранг 1 на  $C = 7$  и  $C = 321$ , при  $H=336$ , но ранг 2 на  $C=21$
- variate: немонотонное поведение
- дискретные стратегии устойчиво слабые во всём диапазоне



# Заключение и вклады работы

---

## Таксономия

4 семейства токенизации с формальными определениями  $L_\tau$  и стоимости внимания

---

## Контролируемый бенчмарк

90 запусков, ~230 GPU-часов, единый трансформер-бэкбон

---

## Три эмпирических результата

patch побеждает в 5/6 ячеек; разрыв по вычислениям до 186×; patch доминирует по обоим критериям

---

## Решающее правило(RQ3)

$\tau^* = \text{patch}$  - операционная рекомендация для выбора токенизатора



# Ограничения и дальнейшая работа

## Текущие ограничения

### Малая матрица

3 датасета × 2 горизонта × 3 инициализации —  
недостаточно для статистически значимого  
решающего дерева

## Направления продолжения



### Расширение матрицы

Дополнительные датасеты, горизонты и  
размерности для построения нетривиального  
решающего дерева



**Полное воспроизведение  
именованных архитектур в рамках  
единого протокола**

# **Спасибо за внимание!**

**Буду рад ответить на Ваши вопросы, если они возникли.**