

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Исследовательский проект на тему:

Унификация токенизации:

поиск оптимальной стратегии для моделей временных рядов

Выполнил студент:

группы #БПМИ224, 4 курса

Вдонин Алексей Васильевич

Принял руководитель ВКР:

Темирханов Азиз Арсенович

Младший научный сотрудник лаборатории

методов анализа больших данных LAMBDA

Факультет компьютерных наук

Содержание

Аннотация	4
Ключевые слова	4
1 Введение	5
2 Обзор литературы	7
2.1 От точечных представлений к патчам и переменным	7
2.2 Дискретная токенизация и сопряжение с языковыми моделями	7
2.3 Истоки символьного представления и оставшийся пробел	8
3 Постановка задачи	9
4 Выбор методов решения и обоснование	10
4.1 Двухуровневый протокол сравнения	11
4.2 Состав сравниваемых стратегий	11
4.3 Бэкбон, обучение и протокол воспроизводимости	12
4.4 Экспериментальная матрица	13
5 План решения поставленной задачи	13
6 Полученные результаты	14
6.1 Сводные метрики качества	14
6.2 Вычислительные затраты по токенизаторам	16
6.3 Ранжирование по функционалу полезности	17
6.4 Парето-анализ	17
6.5 Зависимость от размерности данных (RQ2)	18
6.6 Решающее правило (RQ3)	19
6.7 Парные тесты значимости	20
7 Заключение	20
Список литературы	22
А Репозиторий с кодом и материалами	25
В Сводка ключевых гиперпараметров	25

Аннотация

В современных архитектурах на основе трансформеров выбор стратегии токенизации — преобразования непрерывного сигнала в последовательность токенов, поступающих в трансформер — становится одним из центральных архитектурных решений и непосредственно влияет на качество прогноза, длину контекстного окна, вычислительную сложность и расход памяти. Литература предлагает четыре базовых подхода к токенизации: точечный, патч-ориентированный, поканальный и дискретный — однако сравнения между ними традиционно проводятся внутри различных архитектур и при различных бюджетах обучения, что не позволяет ответить на вопрос об относительной эффективности самой стратегии. В настоящей работе разработан единый аналитический и экспериментальный подход к контролируемому сравнению пяти представителей четырёх семейств: точечного, патч-ориентированного, поканального, скалярного дискретного и дискретного с обучаемым словарём BPE. Полная экспериментальная серия из 90 контролируемых запусков (5 токенизаторов $\times$ 3 датасета $\times$ 2 горизонта $\times$ 3 случайных инициализации) выполнена на одном GPU NVIDIA RTX 5090 (32 ГБ VRAM). Суммарный объём вычислений составил приблизительно **230 GPU-часов**. Собрана сводная таблица метрик, построены парето-фронты «качество — вычислительные ресурсы», выполнен парный статистический тест Уилкоксона. Помимо различий в качестве выявлен второй существенный фактор различения стратегий — расход вычислений: между самым быстрым и самым медленным токенизатором в одной ячейке наблюдалось расхождение во времени обучения до 186 раз, что напрямую отражается на ранжировании при ориентации функционала полезности на затраты, а не только на качество.

Ключевые слова

Глубинное обучение, временные ряды, токенизация, трансформер, прогнозирование, представления данных, парето-анализ.

1 Введение

Прогнозирование многомерных временных рядов является одной из центральных прикладных задач машинного обучения и применяется в энергетике, финансовом секторе, транспорте, климатических исследованиях, промышленном мониторинге и многих других областях. В последние годы в этой подобласти доминируют архитектуры на основе трансформеров, в которых ключевым проектным решением становится не только устройство самой модели, но и способ преобразования непрерывного сигнала в последовательность токенов, поступающих в трансформер. Этот способ преобразования принято называть *стратегией токенизации*. Он непосредственно влияет на качество прогноза, длину контекстного окна, вычислительную сложность и расход памяти.

В современной литературе сложились четыре базовых семейства стратегий токенизации многомерных временных рядов: точечное (один токен на момент времени), патч-ориентированное (один токен на короткий патч соседних значений одного канала), каналальное (один токен на канал) и дискретное (квантование значений в фиксированный или обучаемый словарь). Каждое из этих семейств опирается на собственное индуктивное смещение и собственные допущения о структуре данных. Существующие сравнения между ними традиционно проводятся внутри различных архитектур и при различных бюджетах обучения, что не позволяет ответить на главный вопрос: при прочих равных, какая стратегия токенизации эффективнее, в каких условиях и по каким критериям. Неформально, задача настоящей работы — провести контролируемое сравнение представителей четырёх семейств токенизации на едином трансформер-бэббоне с одинаковым бюджетом обучения и сформулировать практическое правило выбора стратегии в зависимости от свойств данных.

Тема актуальна одновременно по нескольким направлениям. Во-первых, исследования архитектур-фундаментальных моделей (foundation models) явно ставят токенизатор в центр пайплайна, поскольку именно он определяет, как непрерывный сигнал отображается в последовательность, обрабатываемую трансформером [1, 2]. Во-вторых, рост популярности языковых моделей при обработке временных рядов [3, 4] требует совмещения числовых сигналов с дискретно-словарной парадигмой, что снова делает токенизацию ключевым проектным решением. В-третьих, попытки построить универсальные модели, переносимые между датасетами разной частоты, размерности и физической природы [5, 6], наталкиваются на проблему общего токенизатора, способного работать на разнородных режимах.

В то же время в литературе сохраняется методологический пробел: каждое из существующих исследований выбирает одну стратегию токенизации и оценивает её внутри соб-

ственной архитектуры с собственным бюджетом обучения и собственным набором датасетов. PatchTST [7] демонстрирует выигрыш патч-ориентированной токенизации, iTransformer [8] показывает преимущества поканальной на высокоразмерных данных, Chronos [4] и TOTEM [9] — потенциал дискретной. Однако общий контролируемый бенчмарк, где варьировалась бы только стратегия токенизации при одинаковых условиях во всем остальном, в доступной литературе найти не удалось. Более того, недавняя работа [10] прямо обращает внимание на то, что эффективная область внимания и итоговое качество существенно зависят от выбора токенизатора, а не только от архитектурных деталей. Таким образом, актуальность темы определяется одновременно (1) переходом всей подобласти к проектированию пайплайнов вокруг компонент представления, а не вокруг конкретных названий моделей, и (2) практической потребностью в обоснованном выборе стратегии токенизации при ограниченном бюджете обучения.

В настоящей работе разработан единый аналитический и экспериментальный подход к контролируемому сравнению пяти представителей четырёх семейств токенизации: точечного, патч-ориентированного, поканального, скалярного дискретного и дискретного с обучаемым словарём BPE. Сравнение проведено на едином трансформер-бэббоне с одинаковыми гиперпараметрами, оптимизатором и бюджетом обучения, что позволяет максимально изолировать эффект самой токенизации от прочих архитектурных решений. Полная экспериментальная серия из 90 контролируемых запусков на трёх публичных бенчмарках (ETTh1, Weather, Electricity) при двух горизонтах ($H \in \{96, 336\}$) и трёх случайных инициализациях успешно завершена на одном GPU NVIDIA RTX 5090 (32 ГБ VRAM); суммарный объём вычислений составил приблизительно 230 GPU-часов или 9,5 суток непрерывных вычислений.

Новизна и значимость. В отличие от большинства существующих публикаций, в которых стратегия токенизации тестируется внутри собственной архитектуры с собственным бюджетом обучения, в настоящей работе впервые проведено сравнение пяти представителей четырёх семейств токенизации в условиях фиксированного трансформер-бэббона, единого набора гиперпараметров, одинакового бюджета обучения и общего набора датасетов; это позволяет напрямую изолировать эффект самой стратегии токенизации. Введён единый функционал полезности, объединяющий качество прогноза, вычислительные затраты, расход памяти и устойчивость к случайной инициализации. На его основе построено эмпирическое правило выбора стратегии токенизации в зависимости от свойств датасета. Полученные результаты обеспечивают переход от наблюдения отдельных успехов отдельных токенизаторов к более принципиальному пониманию проектирования представления входных данных для нейросетевых моделей временных рядов.

2 Обзор литературы

2.1 От точечных представлений к патчам и переменным

Ранние трансформер-модели прогнозирования работали на *точечных* токенах, в которых каждый момент времени образует один токен, содержащий все наблюдаемые переменные сразу. Такое представление сохраняет исходную длину последовательности и максимально мелкое временное разрешение, но смешивает разнородные физические каналы внутри одного токена и, что важнее, приводит к высокой стоимости самовнимания на длинных контекстах. PatchTST [7] в качестве токена использует не отдельную точку, а патч из p соседних значений одного канала. У такого решения сразу несколько следствий: локальный временной паттерн целиком попадает внутрь одного токена, длина последовательности уменьшается пропорционально страйду, а доступный модели контекст пропорционально расширяется без роста квадратичной сложности внимания. В iTransformer [8] выбран противоположный угол зрения: токеном становится не отрезок времени, а отдельная переменная, — и самовнимание начинает работать на уровне кросс-канальных зависимостей. На датасетах с большим числом каналов такая перестановка ролей даёт ощутимый выигрыш. Сравнительный анализ в статье [10] объединяет все три варианта и показывает, что каждый из них формирует свою эффективную область внимания и своё индуктивное смещение; авторы также отмечают, что простые архитектуры, выстроенные вокруг подходящего токенизатора, на ряде бенчмарков превосходят значительно более сложные модели.

Из этих работ следует достаточно очевидный вывод: токенизация задаёт первое индуктивное смещение задолго до того, как сигнал попадает в слой внимания. Патчи укрупняют локальную динамику и тем самым позволяют модели видеть более длинный контекст. Поканальный токен лучше изолирует физически разнородные каналы. Точечный токен сохраняет максимальное временное разрешение, но плохо масштабируется на длинные горизонты. Литература фактически признаёт существование компромисса между гранулярностью, локальностью и стоимостью, но единого критерия для его разрешения до сих пор не предложила.

2.2 Дискретная токенизация и сопряжение с языковыми моделями

Альтернатива непрерывному входу — заменить значения временного ряда дискретными символами. Chronos [4] реализует эту идею самым прямолинейным образом: значения масштабируются и квантуются в фиксированный словарь, после чего прогнозирование сводится к стандартной задаче языкового моделирования (предсказанию следующего токена).

TOTEM [9] опирается на ту же дискретизацию, но кодовая книга в нём не задаётся заранее, а обучается, и одна и та же книга затем переиспользуется в нескольких кросс-доменных задачах. LLMTime [3] обходится без отдельного словаря вовсе: числа просто записываются как текстовые строки и подаются в большую языковую модель без ее дополнительного дообучения на такую задачу. Авторы демонстрируют, что подход рабочий, однако качество критически зависит от того, как именно числа разбиваются на символы. В статье [11] к временным рядам применяют byte pair encoding: частые мотивы объединяются в составные токены, длина последовательности становится переменной, а пайплайны фундаментальных моделей заметно ускоряются.

Это направление интересно прежде всего тем, что переосмысляет токенизацию как мост между числовыми сигналами и дискретно-словарными моделями. Дискретные токены упрощают переиспользование предобученных языковых моделей, дают общий словарь между разнородными датасетами и сокращают длину последовательности. С другой стороны, квантование неизбежно теряет часть информации — и тут же возникает вопрос, насколько сильно можно сжать сигнал, не потеряв в качестве прогноза.

2.3 Истоки символьного представления и оставшийся пробел

История дискретных представлений временных рядов заметно длиннее истории нейросетевых архитектур. Один из ранних классических методов — SAX [12]: нормализованные сегменты квантуются в символы, причём так, что нижние оценки расстояний на полученных строках доказуемо мажорируют расстояния в исходном сигнале, что было важно для алгоритмов поиска и кластеризации того времени. Последующие расширения [13] применили тот же приём к классификации, обнаружению аномалий и визуализации временных рядов. Современная дискретная токенизация унаследовала по сути ту же логику: вместо сырых непрерывных траекторий — компактные, ориентированные на задачу символьные или полу-символьные единицы.

Одновременно подъём фундаментальных моделей изменил масштаб, на котором решения о токенизации становятся значимыми. Moirai [5] обучает универсальный трансформер прогнозирования на гетерогенных датасетах, и потому вынужден решать задачи кросс-частотного обучения, произвольного числа переменных и распределительного смещения. TimesFM [6] аналогичным образом показывает, что декодер-only модель с патчированием способна давать сильные прогнозы без дообучения на разнородных датасетах. Обзоры [1, 2] подтверждают центральное место токенизации в более широких вопросах переноса, унифи-

кации и мультимодального согласования.

Неразрешённый пробел. Несмотря на этот прогресс, литература остаётся фрагментированной. Большинство существующих исследований оценивают токенизацию внутри конкретной архитектуры, при разном числе параметров, разных датасетах, разных бюджетах обучения и разных целевых функциях. Поэтому неразрешённый пробел — не отсутствие успешных методов токенизации, а отсутствие общего критерия выбора стратегии. Заполнение этого пробела составляет суть настоящей работы.

3 Постановка задачи

Пусть многомерный временной ряд задан матрицей наблюдений

$$X = [x_1, x_2, \dots, x_T] \in \mathbb{R}^{C \times T}, \quad (1)$$

где C — число переменных (каналов), T — длина окна контекста. **Стратегией токенизации** называется отображение

$$\tau : \mathbb{R}^{C \times T} \rightarrow \mathcal{Z}^L, \quad (2)$$

переводящее исходный ряд в последовательность из L токенов

$$Z = \tau(X) = (z_1, z_2, \dots, z_L). \quad (3)$$

Прогнозирующая модель f_θ оперирует уже на токенизированном представлении: $\hat{Y} = f_\theta(Z)$. Выбор τ влияет одновременно на информационную содержательность каждого токена и на длину последовательности L . Поскольку доминирующая часть стоимости полносвязного механизма самовнимания пропорциональна квадрату длины последовательности,

$$\text{Cost}_{\text{attn}}(\tau) = O(L_\tau^2 d), \quad (4)$$

(d — размерность скрытого представления), стратегия токенизации непосредственно определяет вычислительный бюджет и бюджет памяти всего пайплайна.

Понятие оптимальной стратегии. В работе принят операционный критерий выбора стратегии: для семейства датасетов $\mathcal{D}$ и фиксированного бюджета B предпочитаемая стратегия — это та, что максимизирует функционал полезности, объединяющий качество,

вычислительные затраты, расход памяти и устойчивость:

$$U(\tau; \mathcal{D}, B) = w_q \tilde{Q} - w_t \tilde{T} - w_m \tilde{M} + w_s \tilde{S}, \quad (5)$$

где $\tilde{Q}$ — нормализованное качество прогноза, $\tilde{T}$ — нормализованные затраты на обучение или инференс, $\tilde{M}$ — пиковое потребление памяти, $\tilde{S}$ — устойчивость к выбору случайных значений инициализации. Все компоненты приводятся к единому масштабу min-max-нормализацией внутри каждой клетки экспериментальной матрицы, что позволяет сопоставлять токенизаторы напрямую. Веса w_q, w_t, w_m, w_s задаются явно и подвергаются анализу чувствительности: помимо равной конфигурации (0,25; 0,25; 0,25; 0,25) рассматриваются *ориентированная на качество* (0,70; 0,10; 0,10; 0,10) и *ориентированная на развертывание* (0,25; 0,40; 0,25; 0,10) конфигурации.

Исследовательские вопросы. Работа структурирована тремя исследовательскими вопросами:

- RQ1.** Как точечная, патч-ориентированная, поканальная и дискретная стратегии токенизации различаются по предсказательному качеству в условиях контролируемого эксперимента?
- RQ2.** Какие свойства данных (размерность C , длина горизонта H , временная регулярность) ассоциированы с относительным успехом конкретной стратегии?
- RQ3.** Возможно ли получить операционное решающее правило, рекомендуемое стратегии токенизации в зависимости от свойств датасета и заданных критериев качества и эффективности?

Данные вопросы определяют структуру эмпирического исследования и переходят далее в разделы, посвящённые методам, реализации и результатам.

4 Выбор методов решения и обоснование

Эмпирическое ядро работы сосредоточено на задаче долгосрочного многомерного прогнозирования. Этот выбор сделан не случайно: именно прогнозирование наиболее непосредственно связано с длиной контекста, структурой внимания и точностью выхода и одновременно является той задачей, для которой патч-ориентированные, поканальные и дискретные подходы наиболее зрелые [7, 8, 4, 5, 6].

4.1 Двухуровневый протокол сравнения

Методологическая трудность сравнения токенизаторов состоит в том, что выбор стратегии часто переплетается с архитектурой. В работе принят двухуровневый протокол:

Уровень 1: общий бэкбон. Каждая из пяти стратегий токенизации поступает на один и тот же лёгкий трансформер-энкодер с одинаковыми гиперпараметрами, оптимизатором и бюджетом обучения. Это *единственный экспериментальный уровень настоящей работы* — он позволяет максимально изолировать эффект самой токенизации.

Уровень 2: репрезентативные модели. Помимо контролируемого Уровня 1 в литературе существуют именованные модели, привязанные к конкретным стратегиям (PatchTST, iTransformer, Chronos/TOTEM, TimesFM/Moirai). В настоящей работе они используются как литературный контекст для обсуждения, но *не воспроизводятся эмпирически*, поскольку каждая из них вводит собственные архитектурные решения, выходящие за рамки токенизации, и их повторный запуск не даёт дополнительной информации о самой токенизации.

4.2 Состав сравниваемых стратегий

Сравниваются пять токенизаторов, представляющих четыре семьи:

1) Точечный токенизатор. Каждое скалярное значение временного ряда независимо проецируется в скрытое пространство, стратегия применяется поканально (channel-independent):

$$z_{c,t} = \phi(x_{c,t}), \quad L_{\text{point}} = T, \quad (6)$$

где $\phi : \mathbb{R} \rightarrow \mathbb{R}^d$ — линейная проекция скаляра в скрытое пространство размерности d . Каналы обрабатываются как независимые потоки длины T : эффективное батч-измерение перед бэкбоном составляет $B \cdot C$.

2) Патч-ориентированный токенизатор. Соседние точки одного канала группируются в патчи длины p со страйдом s ; стратегия применяется поканально (channel-independent):

$$z_{c,i} = \phi(X_{c, t_i:t_i+p-1}), \quad L_{\text{patch}} = \left\lfloor \frac{T-p}{s} \right\rfloor + 1. \quad (7)$$

Используются канонические значения $p = 16$, $s = 8$, восходящие к PatchTST [7]. Кодировщик $\phi : \mathbb{R}^p \rightarrow \mathbb{R}^d$ — линейная проекция патча в скрытое пространство, каналы обрабатываются как независимые потоки длины L_{patch} .

3) Поканальный токенизатор. Каждый канал становится одним токеном, постро-

енным по всей его истории:

$$z_c = \phi(X_{c,1:T}), \quad L_{\text{var}} = C. \quad (8)$$

Кодировщик ϕ реализован двухслойным MLP с активацией GELU.

4) Скалярный дискретный токенизатор (Chronos-стиль). После канального масштабирования по среднему модулю $\overline{|x_c|} = \frac{1}{T} \sum_{t=1}^T |x_{c,t}|$ значения квантуются в равномерные корзины на отрезке $[-15, +15]$ при общем словаре $V = 4096$:

$$\tilde{x}_{c,t} = \frac{x_{c,t}}{\overline{|x_c|}}, \quad z_{c,t} = Q(\tilde{x}_{c,t}) \in \{1, \dots, V\}. \quad (9)$$

Параметры выбраны в соответствии с оригинальной статьёй Chronos [4].

5) Дискретный с обучаемым словарём ВРЕ. Стратегия (4) дополняется построением словаря частотных мотивов с использованием byte pair encoding. Базовый словарь — $V_{\text{base}} = 126$, конечный — $|V| = 2445$, что соответствует конфигурации с низкой степенью сжатия [11].

Все пять токенизаторов получают на вход стандартизованный (по статистикам обучающей выборки) тензор $X \in \mathbb{R}^{B \times C \times T}$ и выдают пакет токенов согласованного формата для подачи в общий бэкбон.

4.3 Бэкбон, обучение и протокол воспроизводимости

Бэкбон — энкодер-only трансформер с пред-нормализацией и завершающим LayerNorm, согласованный со средне-крупной конфигурацией PatchTST [7]: $d_{\text{model}} = 128$, $d_{\text{ff}} = 256$, $h = 16$ голов, $L = 3$ слоя, $\text{dropout} = 0,2$, активация GELU. Применяется обучаемая позиционная таблица. В слое внимания используется маска паддинга для поддержки токенизации переменной длины (ВРЕ).

Обучение выполняется оптимизатором AdamW (начальная скорость обучения 10^{-4} , weight decay 10^{-4}), с расписанием OneCycle + cosine и 10 % разогрева. Активирована смешанная точность `bf16-mixed` для ускорения и снижения объёма памяти, ограничение нормы градиентов $\|\nabla\| \leq 1$, размер батча $B = 128$. Допустимое число эпох — 100, с ранним остановом при отсутствии улучшения метрики MAE на валидации в течение 10 эпох подряд. Все эксперименты проведены в единообразном программном и физическом окружении на личном физическом сервере (одна и та же фиксированная версия PyTorch и CUDA на одной аппаратной платформе — GPU NVIDIA RTX 5090, 32 ГБ VRAM), что обеспечивает сопоставимость измеренного времени обучения и пиковой памяти между ячейками. Каждая ячейка матрицы

выполнена при трёх случайных значениях инициализации генератора (2021, 2022, 2023), все отчётные значения являются средними по этим трём запускам, с указанием стандартного отклонения.

Фактические непредвиденные корректировки. Датасет Electricity содержит $C = 321$ канал — на порядок больше, чем ETTh1 (7) и Weather (21). При поканально-независимой токенизации эффективный размер батча равен $B \cdot C$, и для $B = 128$ это превышает доступную видеопамять. Поэтому для всех ячеек Electricity использовался уменьшенный батч $B = 8$, а скорость обучения была пропорционально пересчитана по правилу квадратного корня:

$$\text{lr} = 10^{-4} \cdot \sqrt{8/128} \approx 2,5 \cdot 10^{-5}.$$

Эта пара (B, lr) применялась ко всем пяти токенизаторам Electricity без исключений, благодаря чему внутри ячейки по-прежнему менялась только стратегия токенизации, а остальные параметры обучения оставались общими для всех клеток матрицы. Поправка позволила довести до конца все 90 запусков, в том числе наиболее ресурсоёмкие комбинации (`point`, `discrete_scalar` и `discrete_bpe` на Electricity). Цена решения — увеличенное время обучения, разобранные отдельно в разд. 6.2.

4.4 Экспериментальная матрица

Таблица 4.1: Экспериментальная матрица. Всего $5 \times 3 \times 2 \times 3 = 90$ запусков.

Параметр	Значения
Токенизатор	<code>point</code> , <code>patch</code> , <code>variate</code> , <code>discrete_scalar</code> , <code>discrete_bpe</code>
Датасет (C)	ETTh1 (7), Weather (21), Electricity (321)
Окно контекста T	336 (фиксировано)
Горизонт H	96, 336
Случайные инициализации	{2021, 2022, 2023}

Канонические PatchTST-сплиты [7] (12/4/4 месяцев для ETTh1; 70/10/20 для Weather и Electricity) применяются с поправкой `border1 == lookback` для валидационной и тестовой выборок, что обеспечивает совместимость с опубликованными результатами по PatchTST / Autoformer.

5 План решения поставленной задачи

Экспериментальное исследование выстроено по принципу полностью контролируемого сравнения: единственной переменной величиной внутри каждой ячейки матрицы явля-

ется стратегия токенизации, все прочие компоненты пайплайна общие. Пайплайн состоит из четырёх последовательных стадий — (1) подготовка данных с применением канонических сплитов и каналльно-независимой нормализацией по статистикам обучающей выборки, (2) прохождение через выбранный токенизатор, преобразующий тензор формы (B, C, T) в последовательность токенов, (3) обработка общим трансформер-бэкбоном и декодирование в прогноз формы (B, H, C) , (4) оценка качества и эффективности на тестовой выборке.

По каждому запуску собираются качественные показатели — MAE и RMSE на валидации и тесте, а также показатели эффективности: суммарное время обучения, латентность инференса в пересчёте на батч, пиковое потребление видеопамяти, фактическое число токенов на вход и распределение числа параметров между токенизатором, бэкбоном и выходной головой. Этот расширенный набор метрик позволяет ранжировать стратегии не только по качеству прогноза, но и по практическим эксплуатационным затратам, что является существенным компонентом сформулированного функционала полезности (5).

Агрегация результатов производилась следующим образом: 90 индивидуальных запусков сводились в единый артефакт, по которому затем рассчитывались средние и стандартные отклонения по случайным инициализациям, формировались таблицы итоговых метрик, парето-диаграммы и сводное решающее правило по RQ3. Все вычисления выполнены в едином программном окружении на одной аппаратной платформе (см. 4), что обеспечивает сопоставимость показателей времени и памяти между всеми клетками матрицы.

6 Полученные результаты

В этом разделе обобщаются эмпирические результаты, полученные в ходе успешно завершённой экспериментальной серии из всех 90 запусков матрицы. Все таблицы и диаграммы получены агрегированием индивидуальных запусков по случайным инициализациям. Суммарный объём вычислений составил приблизительно 230 GPU-часов на одном GPU NVIDIA RTX 5090 или 9,5 суток непрерывных вычислений.

6.1 Сводные метрики качества

Таблица 6.1 приводит средние значения метрик MAE и RMSE на тестовой выборке для всех пяти токенизаторов на каждой из шести ячеек (*датасет* $\times$ *горизонт*), вычисленные по трём случайным инициализациям, вместе со стандартным отклонением. Каждая строка таблицы агрегирует три успешно завершённых запуска (по трём случайным инициализациям);

итого 30 строк, что соответствует полному покрытию матрицы $5 \times 3 \times 2$. Таблица составляет основу ответа на исследовательский вопрос RQ1.

Из таблицы 6.1 видно, что патч-ориентированная стратегия выигрывает в пяти из шести ячеек по среднему значению MAE; единственное исключение — Weather/ $H = 336$, где наилучшим оказывается точечный токенизатор. Дискретные стратегии (`discrete_scalar`, `discrete_bpe`) уступают непрерывным во всех ячейках, что согласуется с известной потерей информации при квантовании. Поканальная стратегия (`variate`) удерживает значение MAE, близкое к минимальному в ячейке, и на низкоразмерном ETTh1 ($C = 7$), и на высокоразмерном Electricity ($C = 321$). Её относительный провал по качеству приходится на промежуточный по размерности Weather ($C = 21$), особенно при $H = 336$. Зависимость качества поканальной стратегии от размерности данных в наблюдаемой матрице оказывается немонотонной.

Таблица 6.1: Сводные результаты: MAE и RMSE (среднее $\pm$ стандартное отклонение по случайным инициализациям) по всем 30 строкам экспериментальной матрицы $5 \times 3 \times 2$. Каждая строка — среднее по трём успешно завершённым запускам.

Dataset/Horizon	Tokenizer	MAE	RMSE	seeds
ETTh1/H=96	discrete_bpe	0.668 ± 0.023	0.913 ± 0.016	3
ETTh1/H=96	discrete_scalar	0.548 ± 0.009	0.774 ± 0.011	3
ETTh1/H=96	patch	0.427 ± 0.006	0.641 ± 0.008	3
ETTh1/H=96	point	0.484 ± 0.013	0.728 ± 0.016	3
ETTh1/H=96	variate	0.447 ± 0.010	0.648 ± 0.010	3
ETTh1/H=336	discrete_bpe	0.789 ± 0.022	1.033 ± 0.028	3
ETTh1/H=336	discrete_scalar	0.619 ± 0.012	0.839 ± 0.011	3
ETTh1/H=336	patch	0.523 ± 0.008	0.752 ± 0.014	3
ETTh1/H=336	point	0.539 ± 0.031	0.764 ± 0.041	3
ETTh1/H=336	variate	0.535 ± 0.006	0.734 ± 0.006	3
Electricity/H=96	discrete_bpe	0.761 ± 0.001	0.916 ± 0.001	3
Electricity/H=96	discrete_scalar	0.294 ± 0.002	0.456 ± 0.003	3
Electricity/H=96	patch	0.227 ± 0.001	0.362 ± 0.000	3
Electricity/H=96	point	0.276 ± 0.005	0.429 ± 0.006	3
Electricity/H=96	variate	0.247 ± 0.002	0.379 ± 0.002	3
Electricity/H=336	discrete_bpe	0.802 ± 0.001	0.969 ± 0.001	3
Electricity/H=336	discrete_scalar	0.295 ± 0.001	0.454 ± 0.001	3
Electricity/H=336	patch	0.263 ± 0.001	0.409 ± 0.001	3
Electricity/H=336	point	0.285 ± 0.000	0.441 ± 0.001	3
Electricity/H=336	variate	0.282 ± 0.006	0.418 ± 0.007	3
Weather/H=96	discrete_bpe	0.310 ± 0.000	0.504 ± 0.001	3
Weather/H=96	discrete_scalar	0.259 ± 0.010	0.457 ± 0.013	3
Weather/H=96	patch	0.224 ± 0.003	0.403 ± 0.002	3
Weather/H=96	point	0.226 ± 0.004	0.406 ± 0.007	3
Weather/H=96	variate	0.237 ± 0.005	0.427 ± 0.009	3
Weather/H=336	discrete_bpe	0.518 ± 0.002	0.728 ± 0.003	3
Weather/H=336	discrete_scalar	0.343 ± 0.001	0.547 ± 0.005	3
Weather/H=336	patch	0.339 ± 0.006	0.553 ± 0.010	3
Weather/H=336	point	0.312 ± 0.006	0.510 ± 0.004	3
Weather/H=336	variate	0.388 ± 0.007	0.622 ± 0.013	3

6.2 Вычислительные затраты по токенизаторам

Помимо качества прогноза, контролируемая экспериментальная серия позволила измерить непосредственный расход вычислительных ресурсов каждой из пяти стратегий в единых условиях. Сводка средних значений времени обучения по ячейкам и итоговых сумм по токенизаторам приведена в таблице 6.2.

Таблица 6.2: Среднее время обучения одной случайной инициализации (среднее по трём запускам) по ячейкам экспериментальной матрицы; итоговая строка — суммарное время по всем 18 запускам соответствующего токенизатора. Сокращения: `disc_scalar` — `discrete_scalar`, `disc_bpe` — `discrete_bpe`.

Датасет	H	point	patch	variate	disc_scalar	disc_bpe
ETTh1	96	2.3 мин	14 с	11 с	3.3 мин	12.9 мин
ETTh1	336	2.0 мин	11 с	14 с	2.5 мин	12.3 мин
Weather	96	49.6 мин	2.5 мин	36 с	1.6 ч	1.7 ч
Weather	336	57.5 мин	2.1 мин	31 с	1.6 ч	1.3 ч
Electricity	96	9.6 ч	50.3 мин	14.3 мин	21.8 ч	3.5 ч
Electricity	336	10.4 ч	34.8 мин	10.3 мин	19.4 ч	1.6 ч
Vcero	—	65.5 ч	4.5 ч	1.3 ч	133.4 ч	25.5 ч

Расхождение между стратегиями исключительно велико. По 18 запускам каждого токенизатора суммарное время обучения распределилось следующим образом: `variate` — 1,3 ч; `patch` — 4,5 ч; `discrete_bpe` — 25,5 ч; `point` — 65,5 ч; `discrete_scalar` — 133,4 ч. Совокупный расход всех 90 запусков составил приблизительно **230 GPU-часов**, при этом два самых дорогих токенизатора (`discrete_scalar` и `point`) ответственны примерно за 86% всех затраченных вычислений, тогда как два самых дешёвых (`variate` и `patch`) укладываются в 2,5%.

В пересчёте на отдельную ячейку отношение времени обучения самого медленного токенизатора к самому быстрому в одной и той же клетке колеблется от $67\times$ ($\text{ETTh1}/H = 336$) до $186\times$ ($\text{Weather}/H = 336$), на *Electricity* это отношение достигает $113\times$. Иными словами, при равном бэкбоне и одинаковом бюджете обучения разница в расходах между разумными выборами стратегии токенизации может составлять два порядка величины. Это наблюдение является не следствием инженерных решений, а прямым следствием формулы $\text{Cost}_{\text{attn}} = O(L_\tau^2 d)$: длина последовательности L_τ , диктуемая самой стратегией токенизации, доминирует над всеми остальными переменными бюджета.

Поэтому при сопоставлении стратегий нельзя ограничиваться сравнением только по качеству прогноза — любая «лучшая по MAE» стратегия должна быть представлена в паре со своими затратами. Этот тезис явно учтён в выводах настоящей работы (см. 6.3 и заключение).

6.3 Ранжирование по функционалу полезности

Для агрегированной интерпретации различий между стратегиями построен функционал полезности (5) при трёх весовых конфигурациях: равной, качественно-ориентированной и развёртывание-ориентированной. Таблица 6.3 представляет средние значения U по всем шести ячейкам матрицы. Сравнение крайних столбцов (качественно-ориентированной и развёртывание-ориентированной) позволяет оценить, как меняется ранжирование при сдвиге приоритетов от точности к стоимости.

Из таблицы 6.3 видно, что `patch` — единственный токенизатор, доминирующий в обеих крайних конфигурациях весов одновременно: 0,757 при ориентации на качество и 0,313 при ориентации на эффективность. В *качественно-ориентированной* конфигурации второй и третий ранги делят `variate` (0,636) и `point` (0,618). В *развёртывание-ориентированной* конфигурации точечная стратегия резко проседает по абсолютному значению U (0,051, третье место), а `variate` сохраняет конкурентоспособное второе место (0,206) — прямое следствие её малой длины последовательности ($L = C$) и наименьшего среднего времени обучения. Скалярный дискретный токенизатор уходит в отрицательную область даже при равных весах, поскольку соединяет потерю качества при квантовании с самым большим объёмом потребляемых вычислений.

Таблица 6.3: Ранжирование токенизаторов по функционалу полезности при трёх конфигурациях весов.

Tokenizer	U (equal)	U (accuracy)	U (deployment)
patch	0.426	0.757	0.313
variate	0.269	0.636	0.206
point	0.158	0.618	0.051
discrete_scalar	-0.037	0.425	-0.253
discrete_bpe	-0.162	-0.065	-0.377

6.4 Парето-анализ

Парето-диаграммы (Рис. 6.1) показывают для каждой ячейки одновременно отношения «качество (MAE) — время обучения» и «качество — пиковая память». Парето-оптимальные точки выделены цветом, доминируемые — серым. Эти диаграммы наглядно показывают, какие из токенизаторов устойчиво лежат на парето-границе и в каких ячейках конкретный токенизатор перестаёт быть конкурентоспособным.




Рис. 6.1: Парето-диаграммы по шести клеткам экспериментальной матрицы. Слева — горизонт $H = 96$, справа — $H = 336$. Сверху вниз: ETTh1, Weather, Electricity. Цветные точки — парето-оптимальные стратегии, серые — доминируемые.

6.5 Зависимость от размерности данных (RQ2)

Для ответа на исследовательский вопрос RQ2 ранг каждого токенизатора (1 — лучший по MAE внутри ячейки) сопоставляется с числом переменных C (см. Рис. 6.2). Логарифмическая шкала по оси C позволяет сопоставлять ETTh1 ($C = 7$), Weather ($C = 21$) и Electricity ($C = 321$) единообразно, а разделение по горизонтам выполнено в виде двух подрисунков (слева $H = 96$, справа $H = 336$), цвет линии соответствует токенизатору. Все пять токенизаторов представлены во всех точках, что позволяет интерпретировать ранги без оговорок о пропущенных запусках.

Наблюдаемая закономерность согласуется с известными теоретическими ожиданиями: патч-ориентированная стратегия удерживает ранг 1 на всём диапазоне размерностей при $H = 96$ и на двух крайних точках ($C = 7$, $C = 321$) при $H = 336$. Поканальная стратегия (*variate*) показывает менее монотонное поведение: ранг 2 как на ETTh1 ($C = 7$), так и на Electricity ($C = 321$), однако ранги 3 и 4 на Weather ($C = 21$). Простая теоретическая гипотеза «ухудшение с ростом C из-за падения временного разрешения» в наблюдаемых ячейках не подтверждается. Для надёжных выводов о зависимости ранга поканальной стратегии от C

требуется расширение матрицы на дополнительные датасеты. Дискретные стратегии остаются устойчиво слабыми во всём диапазоне размерностей, причём ВРЕ-вариант в наблюдаемых ячейках не превзошёл скалярный.




Рис. 6.2: Ранг токенизатора (1 = наилучший внутри ячейки по среднему MAE) в зависимости от числа переменных C при двух горизонтах. Слева — $H = 96$, справа — $H = 336$. Цвет линии соответствует токенизатору; ось C в логарифмическом масштабе.

6.6 Решающее правило (RQ3)

Для ответа на исследовательский вопрос RQ3 в рамках каждой клетки экспериментальной матрицы выделяется эмпирический победитель — токенизатор с наименьшим средним по случайным инициализациям значением MAE на тестовой выборке. Поскольку шесть наблюдаемых ячеек слишком малочисленны для построения статистически значимого решающего дерева на признаках $(C, H, C/T)$ (на практике дерево глубины не более двух при таком объёме либо вырождается в константу, либо переобучается на единичные исключения), правило формулируется напрямую: в табл. 6.4 приведена сводка победителей по ячейкам и явная мажоритарно-исключительная формулировка.

Важное согласование с предыдущим разделом: победитель по качеству, патч-ориентированный токенизатор, одновременно входит в число двух наименее затратных по времени обучения стратегий (см. таблицу 6.2). Тем самым выбор `patch` в качестве рабочей стратегии не сопряжён с компромиссом «качество против стоимости» — этот компромисс возникает, напротив, при выборе альтернативных стратегий (`point`, `discrete_scalar`), не доминирующих в функционале полезности ни при одной из трёх рассмотренных весовых конфигураций, но тратящих кратно больший бюджет вычислений.

Таблица 6.4: Эмпирическое решающее правило (RQ3): таблица победителей по каждой ячейке экспериментальной матрицы и явная мажоритарно-исключительная формулировка. Шесть ячеек слишком малочисленны для нетривиального решающего дерева; данная сводка приведена как опорный шаблон для расширения бенчмарка в дальнейшей работе.

Dataset (C)	Horizon H	Empirical winner τ^*
ETTh1 ($C = 7$)	96	patch
ETTh1 ($C = 7$)	336	patch
Electricity ($C = 321$)	96	patch
Electricity ($C = 321$)	336	patch
Weather ($C = 21$)	96	patch
Weather ($C = 21$)	336	point

Эмпирическое решающее правило: стратегия **patch** оптимальна в 5 из 6 наблюдаемых ячеек. Исключения, при которых лучшим оказался иной токенизатор: **point** (в Weather/ $H = 336$). В первом приближении правило выбора стратегии сводится к $\tau^* = \text{patch}$ с явно перечисленными ячейками-исключениями. Шесть наблюдаемых ячеек не позволяют оценить, обусловлены ли исключения структурными свойствами данных или статистической случайностью. Для построения полноценного дерева классификации потребуется расширение матрицы на дополнительные датасеты и горизонты.

6.7 Парные тесты значимости

Таблица 6.5 обобщает попарный знаково-ранговый критерий Уилкоксона для метрики MAE в каждой ячейке, выполняемый по трём парам наблюдений (по числу случайных инициализаций). Ввиду малого числа парных наблюдений эти p -значения интерпретируются как индикативные, а не как окончательные оценки значимости, они приводятся для полноты и в качестве исходного материала для развёрнутого статистического анализа.

7 Заключение

В ходе настоящей работы был разработан и реализован единый аналитический и экспериментальный подход к контролируемому сравнению стратегий токенизации в нейросетевых моделях многомерных временных рядов. Основные результаты сводятся к четырём следующим вкладам.

1. Таксономия. Сформулирована компактная и операционализированная таксономия из четырёх семейств токенизаторов с явными математическими определениями длины последовательности L_τ и стоимости внимания, что позволяет проектировать эксперименты и обсуждать результаты в общем теоретическом каркасе, а не в терминах конкретных архитектур.

2. Контролируемый бенчмарк. Успешно проведена экспериментальная серия из 90 контролируемых запусков (5 токенизаторов $\times$ 3 датасета $\times$ 2 горизонта $\times$ 3 случайных инициализации) на едином трансформер-бэббоне с одинаковыми гиперпараметрами, одинаковым

бюджетом обучения и одинаковой аппаратной платформой. Суммарный объём вычислений составил приблизительно **230 GPU-часов** на одном GPU NVIDIA RTX 5090.

3. Эмпирические выводы. Контролируемое сравнение даёт три устойчивых наблюдения.

(1) По метрике качества патч-ориентированная стратегия выигрывает в пяти из шести наблюдаемых ячеек с единственным исключением в Weather/ $H = 336$, где побеждает точечный токенизатор.

(2) По метрике расхода вычислений между токенизаторами наблюдается *двух-порядковое* расхождение: в одной ячейке самый медленный токенизатор обучается до $186\times$ дольше самого быстрого; на 18 запусках каждого токенизатора суммарное время варьируется от 1,3 ч (*variate*) до 133,4 ч (*discrete_scalar*), причём два самых дорогих токенизатора потребляют около 86% всех вычислений всей серии.

(3) Стратегия-победитель по качеству (*patch*) одновременно входит в число двух наиболее дешёвых, благодаря чему практический выбор стратегии на изученных датасетах не сопряжён с компромиссом «качество против стоимости» — этот компромисс возникает лишь при выборе альтернативных стратегий, не доминирующих в функционале полезности ни при одной из весовых конфигураций. Совмещение этих наблюдений в рамках функционала полезности приводит к одинаково устойчивому ранжированию при разных конфигурациях весов: *patch* занимает первое место как при качественно-ориентированной ($U = 0,757$), так и при развёртывание-ориентированной ($U = 0,313$) конфигурациях.

4. Исследовательская повестка. По итогам полученных наблюдений намечены два естественных направления дальнейшего исследования, прямо вытекающие из ограничений настоящего эксперимента. (1) Расширение экспериментальной матрицы на дополнительные публичные бенчмарки и более широкий диапазон горизонтов, что необходимо для построения нетривиального решающего дерева на признаках $(C, H, C/T)$: при шести наблюдаемых ячейках такое дерево вырождается или переобучается (см. 6.6). (2) Полная эмпирическая реализация Уровня 2 описанного в 4 двухуровневого протокола — симметричное Уровню 1 сравнение именованных моделей (PatchTST, iTransformer, Chronos/TOTEM, TimesFM/Moirai) на тех же датасетах и горизонтах. Полученное решающее правило является шаблоном, поддающимся уточнению по мере появления новых данных.

В целом, результаты работы обеспечивают переход от наблюдения успехов отдельных токенизаторов к более принципиальному пониманию проектирования представления входных данных для нейросетевых моделей временных рядов, в котором стоимость обучения учитывается на равных правах с качеством прогноза.

Ограничения. Эмпирическое сравнение ограничено тремя датасетами и двумя горизонтами при трёх случайных инициализациях, что не позволяет претендовать на исчерпывающие количественные оценки значимости различий между токенизаторами. Описанный Уровень 2 протокола сравнения (см. 4) в полном объёме не воспроизводится; решающее правило носит иллюстративный характер; для всех ячеек Electricity использована поправка протокола по размеру батча, что обеспечивает завершение всех запусков, но увеличивает время обучения. Все ограничения отражены в соответствующем разделе работы.

Список литературы

- [1] Yuxuan Liang, Haomin Wen, Yuqi Nie, Yushan Jiang, Ming Jin, Dongjin Song, Shirui Pan и Qingsong Wen. “Foundation Models for Time Series Analysis: A Tutorial and Survey”. B: *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. KDD '24. ACM, авг. 2024, с. 6555—6565. DOI: [10.1145/3637528.3671451](https://doi.org/10.1145/3637528.3671451). URL: <http://dx.doi.org/10.1145/3637528.3671451>.
- [2] Xiyuan Zhang, Ranak Roy Chowdhury, Rajesh K. Gupta и Jingbo Shang. *Large Language Models for Time Series: A Survey*. 2024. arXiv: [2402.01801](https://arxiv.org/abs/2402.01801) [cs.LG]. URL: <https://arxiv.org/abs/2402.01801>.
- [3] Nate Gruver, Marc Finzi, Shikai Qiu и Andrew Gordon Wilson. *Large Language Models Are Zero-Shot Time Series Forecasters*. 2024. arXiv: [2310.07820](https://arxiv.org/abs/2310.07820) [cs.LG]. URL: <https://arxiv.org/abs/2310.07820>.
- [4] Abdul Fatir Ansari, Lorenzo Stella, Caner Turkmen, Xiyuan Zhang, Pedro Mercado, Huibin Shen, Oleksandr Shchur, Syama Sundar Rangapuram, Sebastian Pineda Arango, Shubham Kapoor, Jasper Zschiegner, Danielle C. Maddix, Hao Wang, Michael W. Mahoney, Kari Torkkola, Andrew Gordon Wilson, Michael Bohlke-Schneider и Yuyang Wang. *Chronos: Learning the Language of Time Series*. 2024. arXiv: [2403.07815](https://arxiv.org/abs/2403.07815) [cs.LG]. URL: <https://arxiv.org/abs/2403.07815>.
- [5] Gerald Woo, Chenghao Liu, Akshat Kumar, Caiming Xiong, Silvio Savarese и Doyen Sahoo. *Unified Training of Universal Time Series Forecasting Transformers*. 2024. arXiv: [2402.02592](https://arxiv.org/abs/2402.02592) [cs.LG]. URL: <https://arxiv.org/abs/2402.02592>.
- [6] Abhimanyu Das, Weihao Kong, Rajat Sen и Yichen Zhou. *A decoder-only foundation model for time-series forecasting*. 2024. arXiv: [2310.10688](https://arxiv.org/abs/2310.10688) [cs.CL]. URL: <https://arxiv.org/abs/2310.10688>.

- [7] Yuqi Nie, Nam H. Nguyen, Phanwadee Sinthong и Jayant Kalagnanam. *A Time Series is Worth 64 Words: Long-term Forecasting with Transformers*. 2023. arXiv: [2211.14730](https://arxiv.org/abs/2211.14730) [cs.LG]. URL: <https://arxiv.org/abs/2211.14730>.
- [8] Yong Liu, Tengge Hu, Haoran Zhang, Haixu Wu, Shiyu Wang, Lintao Ma и Mingsheng Long. *iTransformer: Inverted Transformers Are Effective for Time Series Forecasting*. 2024. arXiv: [2310.06625](https://arxiv.org/abs/2310.06625) [cs.LG]. URL: <https://arxiv.org/abs/2310.06625>.
- [9] Sabera Talukder, Yisong Yue и Georgia Gkioxari. *TOTEM: TOkenized Time Series EMbeddings for General Time Series Analysis*. 2025. arXiv: [2402.16412](https://arxiv.org/abs/2402.16412) [cs.LG]. URL: <https://arxiv.org/abs/2402.16412>.
- [10] Yu Chen, Nathalia Céspedes и Payam Barnaghi. “A Closer Look at Transformers for Time Series Forecasting: Understanding Why They Work and Where They Struggle”. B: *Forty-second International Conference on Machine Learning*. 2025. URL: <https://openreview.net/forum?id=kHEVCfES4Q>.
- [11] Leon Götz, Marcel Kollovieh, Stephan Günnemann и Leo Schwinn. *Byte Pair Encoding for Efficient Time Series Forecasting*. 2026. arXiv: [2505.14411](https://arxiv.org/abs/2505.14411) [cs.LG]. URL: <https://arxiv.org/abs/2505.14411>.
- [12] Jessica Lin, Eamonn Keogh, Stefano Lonardi и Bill Chiu. “A symbolic representation of time series, with implications for streaming algorithms”. B: *Proceedings of the 8th ACM SIGMOD Workshop on Research Issues in Data Mining and Knowledge Discovery*. DMKD ’03. San Diego, California: Association for Computing Machinery, 2003, с. 2—11. ISBN: 9781450374224. DOI: [10.1145/882082.882086](https://doi.org/10.1145/882082.882086). URL: <https://doi.org/10.1145/882082.882086>.
- [13] Jessica Lin, Eamonn Keogh, Li Wei и Stefano Lonardi. “Experiencing SAX: A Novel Symbolic Representation of Time Series”. B: *Data Min. Knowl. Discov.* 15 (аВГ. 2007), с. 107—144. DOI: [10.1007/s10618-007-0064-z](https://doi.org/10.1007/s10618-007-0064-z). URL: <https://doi.org/10.1007/s10618-007-0064-z>.

Таблица 6.5: p -значения знаково-рангового критерия Уилкоксона по парам токенизаторов в каждой ячейке матрицы.

Dataset/Horizon	Tok A	Tok B	p-value
ETTh1/H=336	patch	discrete_bpe	0.250
ETTh1/H=336	patch	point	0.500
ETTh1/H=336	patch	variate	0.500
ETTh1/H=336	patch	discrete_scalar	0.250
ETTh1/H=336	discrete_bpe	point	0.250
ETTh1/H=336	discrete_bpe	variate	0.250
ETTh1/H=336	discrete_bpe	discrete_scalar	0.250
ETTh1/H=336	point	variate	1.000
ETTh1/H=336	point	discrete_scalar	0.250
ETTh1/H=336	variate	discrete_scalar	0.250
ETTh1/H=96	point	discrete_scalar	0.250
ETTh1/H=96	point	variate	0.250
ETTh1/H=96	point	patch	0.250
ETTh1/H=96	point	discrete_bpe	0.250
ETTh1/H=96	discrete_scalar	variate	0.250
ETTh1/H=96	discrete_scalar	patch	0.250
ETTh1/H=96	discrete_scalar	discrete_bpe	0.250
ETTh1/H=96	variate	patch	0.250
ETTh1/H=96	variate	discrete_bpe	0.250
ETTh1/H=96	patch	discrete_bpe	0.250
Electricity/H=336	discrete_scalar	point	0.250
Electricity/H=336	discrete_scalar	variate	0.250
Electricity/H=336	discrete_scalar	patch	0.250
Electricity/H=336	discrete_scalar	discrete_bpe	0.250
Electricity/H=336	point	variate	0.500
Electricity/H=336	point	patch	0.250
Electricity/H=336	point	discrete_bpe	0.250
Electricity/H=336	variate	patch	0.250
Electricity/H=336	variate	discrete_bpe	0.250
Electricity/H=336	patch	discrete_bpe	0.250
Electricity/H=96	variate	point	0.250
Electricity/H=96	variate	discrete_bpe	0.250
Electricity/H=96	variate	patch	0.250
Electricity/H=96	variate	discrete_scalar	0.250
Electricity/H=96	point	discrete_bpe	0.250
Electricity/H=96	point	patch	0.250
Electricity/H=96	point	discrete_scalar	0.250
Electricity/H=96	discrete_bpe	patch	0.250
Electricity/H=96	discrete_bpe	discrete_scalar	0.250
Electricity/H=96	patch	discrete_scalar	0.250
Weather/H=336	discrete_bpe	point	0.250
Weather/H=336	discrete_bpe	variate	0.250
Weather/H=336	discrete_bpe	patch	0.250
Weather/H=336	discrete_bpe	discrete_scalar	0.250
Weather/H=336	point	variate	0.250
Weather/H=336	point	patch	0.250
Weather/H=336	point	discrete_scalar	0.250
Weather/H=336	variate	patch	0.250
Weather/H=336	variate	discrete_scalar	0.250
Weather/H=336	patch	discrete_scalar	0.500
Weather/H=96	variate	point	0.250
Weather/H=96	variate	discrete_bpe	0.250
Weather/H=96	variate	discrete_scalar	0.250
Weather/H=96	variate	patch	0.250
Weather/H=96	point	discrete_bpe	0.250
Weather/H=96	point	discrete_scalar	0.250
Weather/H=96	point	patch	0.750
Weather/H=96	discrete_bpe	discrete_scalar	0.250
Weather/H=96	discrete_bpe	patch	0.250
Weather/H=96	discrete_scalar	patch	0.250

А Репозиторий с кодом и материалами

Исходный код экспериментального пакета, конфигурации запусков, логи и различные артефакты размещены в репозитории на GitHub:

https://github.com/vdoninav/tokenization_unification

В Сводка ключевых гиперпараметров

Таблица В.1: Зафиксированные гиперпараметры (применяются единообразно ко всем 90 запускам, за исключением поправки по размеру батча и скорости обучения для Electricity).

Параметр	Значение
Размерность скрытого пространства d_{model}	128
Размерность FFN d_{ff}	256
Число голов внимания h	16
Число слоёв L	3
Dropout	0,2
Активация	GELU
Оптимизатор	AdamW
Скорость обучения	10^{-4} (Electricity: $2,5 \cdot 10^{-5}$)
Weight decay	10^{-4}
Расписание	OneCycle + cosine, 10 % разогрева
Размер батча	128 (Electricity: 8)
Окно контекста T	336
Горизонты H	96, 336
Длина патча p	16
Страйд патча s	8
Дискретный словарь V	4096
Базовый словарь BPE V_{base}	126
Целевой словарь BPE $ V $	2445
Случайные инициализации	2021, 2022, 2023
Максимум эпох	100
Терпение раннего останова	10
Норма обрезания градиента	1,0
Точность вычислений	bf16-mixed

С Покрытие экспериментальной матрицы

Полная матрица $5 \times 3 \times 2 \times 3 = 90$ запланированных запусков, все 90 успешно завершены. Распределение по датасетам:

- **ETTh1** ($C = 7$): 30/30 успешно завершённых запусков.
- **Weather** ($C = 21$): 30/30 успешно завершённых запусков.

- **Electricity** ($C = 321$): 30/30 успешно завершённых запусков; для этого датасета размер батча уменьшен с 128 до 8 с компенсирующим перерасчётом скорости обучения — единая поправка протокола, описанная в [4](#).

Суммарный объём вычислений по всем 90 запускам составил приблизительно 230 GPU-часов на одном GPU NVIDIA RTX 5090 (32 ГБ VRAM), распределение вычислительных затрат по ячейкам и по токенизаторам приведено в таблице [6.2](#).